

1. 개발 배경 및 필요성

유튜브 쇼츠, 인스타그램의 릴스 등 숏폼 콘텐츠는 짧은 시간 안에 대량의 사용자에게 확산되며 이러한 특성으로 정보 전달의 주요 수단으로 자리 잡았다. 숏폼 콘텐츠의 등장으로 사용자들에게 신속한 정보 전달이라는 장점을 제공하였으나 이로 인하여 **가짜 뉴스 문제**가 대두되었다. 실제로 세계경제포럼(WEF)은 허위/조작정보를 향후 2년간의 위험 가운데 2025년 1위, 2026년 2위로 평가될 만큼 지속적으로 중요한 문제로 언급되고 있다[1,2]. 최근에는 영상 편집 기술의 발달과 **생성형 AI의 급격한 발전** 및 대중화로 인해 실제처럼 보이는 영상과 음성, 정보 전달글을 제작하기도 쉬워졌다. 선행 연구에서는 생성형 AI가 사실적인 콘텐츠의 대량 생산을 가능하게 하여 **가짜뉴스의 규모와 설득력을 증폭시킬** 가능성이 있다고 지적한다[3]. 또한 실제 정보의 일부분만 편집하여 잘못된 맥락으로 과장되고 자극적인 정보를 전달하는 사례도 발생하고 있다. 이러한 콘텐츠들은 형식만으로는 진위여부를 확인하기 어렵고 사용자가 원본과 관련 자료를 직접 찾아 사실관계를 확인하기도 **매우 번거로운 상황**이다.

물론 전세계적으로 AI 생성 콘텐츠로 인한 허위/조작정보의 확산을 줄이고 콘텐츠의 투명성을 높이기 위한 여러 노력이 이루어지고 있다. EU는 「**AI Act**」에 따라 챗봇과 같은 AI 시스템과 상호작용한 사실을 사용자들에게 명확하게 안내하고 **AI 생성 및 조작 콘텐츠에 식별 정보와 표시를 제공하도록** 규정하였다[4]. 또한 한국도 「**인공지능기본법**」을 시행하여 제품/서비스가 AI에 기반하여 운용된다는 사실을 사용자에게 사전에 고지하고 결과물이 **생성형 AI에 의하여 생성되었다는 사실을 표시**해야된다고 규정하였다[5]. 그러나 이러한 규정들은 콘텐츠가 단순히 AI로 생성되었다는 사실을 알려주는 데 초점이 있어, 콘텐츠에 포함된 주장의 **진위여부와 그에 대한 근거까지는 검증하지 않는다**는 문제가 있다.

그러나 콘텐츠의 진위여부를 판단하기 위해 플랫폼 운영자가 업로드되는 모든 콘텐츠를 직접 검토하는 것도 현실적으로 어려운 일이다. 따라서 **대량의 콘텐츠를 신속하게 분석**하고 원본 출처, 진위여부, 핵심 주장, 관련 근거를 **종합하여 분석**하고 판단이 어려운 경우에는 불확실성을 명확히 표현해주는 기술이 필요하다. 이에 따라 SNS 플랫폼이 콘텐츠마다 검증 결과와 추가자료를 자동으로 제공할 수 있도록 지원하는 **플랫폼용 AI 신뢰 인프라**를 개발하고자 한다.


2. 개발 주제(목적)

본 작품은 SNS에 게시되는 콘텐츠의 원본 출처, 진위여부, 핵심 주장, 관련 근거를 자동으로 분석하여 사용자의 정보 판단을 지원하는 **플랫폼용 B2B AI 신뢰 인프라** 개발을 목적으로 한다. 단순히 콘텐츠에 생성형 AI가 사용되었는지를 표시해주던 기존 AI 생성 콘텐츠 표시 기능에서 나아가 콘텐츠가 무엇을 주장하고 있는지, 어떤 것을 설명하고 있는지, 해당 내용을 뒷받침하는 자료가 존재하는지 함께 제공해줄 것이다. 이를 통해 사용자는 **별도의 번거로운 검색 없이** 콘텐츠를 확인하며 그 콘텐츠의 근거와 신뢰성을 확인할 수 있도록 한다. 이는 독립적인 웹사이트가 아닌 유튜브, 인스타그램과 같은 SNS 플랫폼의 업로드 및 운영 시스템에 **API 형태로 연동**되는 기술을 목표로 한다.


콘텐츠 업로드시 시스템은 영상을 분석하며 주요 프레임, 음성, 자막, 게시글 본문 등 콘텐츠를 복합적으로 분석하여 진위여부를 판단할 **핵심 요소들을 추출**한다. 이후 콘텐츠의 원본 및 유사 정보들, 언론 보도, 연구자료 등을 바탕으로 실제로 검증된, 존재하는 정보인지 판단하고 정보를 가져와서 게시할때 일부가 **과장되거나 편집된 부분이 없는지** 확인하여 근거를 수집한다. 이후 AI 생성 또는 조작 가능성과 출처의 신뢰성 등 여러 요소들을 종합적으로 분석하여 콘텐츠의 신뢰도를 산정하고 그에 대한 결과와 근거를 플랫폼에 전달한다. 이후 플랫폼에서는 검증 내용 및 관련 자료의 형태로 제공한다. 만약 자료간 내용이 충돌하거나 **충분한 근거 수집이 되지 않은 경우에는** 경고 문구로 불확실성을 명확하게 표시한다.

3. 유사 제품(연구) 및 차별점

____과 유사한 기술의 대표적인 예로는 **유튜브의 정보 패널**과 **Meta의 Community Notes**가 있다. **유튜브 정보 패널**의 경우에는 잘못된 정보가 제공될 가능성이 높은 주제를 검색하거나 그와 관련된 동영상을 시청하면 검색 결과 상단 또는 시청 중인 동영상 아래에 정보 패널을 표시하여 주제에 대한 추가 맥락을 제공하기 위해 독립적인 서드 파티 파트너를 출처로 한 정보가 표시된다[6].




[그림1]



[그림2]

그러나 조사 과정에서 유튜브의 언어와 위치를 변경(United States, English)하고 민감한 주제를 검색하여 정보 패널의 노출 여부를 직접 확인하였으나 **실제 검색 화면에서는 정보 패널이 표시되지 않았다.**([그림1] : “Is trump assassinated?”, [그림2] : “moon landing conspiracy”) 유튜브는 해당 기능이 일부 국가/지역 및 언어에서는 정보 패널이 지원되지 않을 수 있다고 안내하고 있으므로, 이는 기능의 부재보다는 지역과 적용 대상에 따른 노출 범위의 차이로 판단된다. 따라서 유튜브 정보 패널은 사용자에게 유용한 정보를 제공하지만, 적용되는 지역이 제한적이고 **적용 주제도 민감한 주제에 한정되어** 제공하기 때문에 **모든 콘텐츠에서 동일하게 확인할 수 없다는** 한계가 있는 것을 확인할 수 있다.

Meta의 Community Notes는 미국에 한하여 Facebook, Instagram, Threads에서 오해의 소지가 있거나 정보가 누락된 게시물에 대하여 사용자가 직접 추가적인 설명과 근거를 제공하는 **사용자 참여형** 정보 제공 기능이다. 사용자는 문제가 있다고 판단되는 게시물에 대해 신뢰할 수 있는 정보들을 작성하여 타사용자들에게 올바른 정보를 전달할 수 있다[7].



[그림3]

Community note	Date added	App
This is a modern day chain letter. It has been circulating on...	August 9, 2026	Facebook
The airspace violation is real, but the post adds unsupported...	August 9, 2026	Facebook
While you can make raisins plump it doesn't turn it into a...	August 9, 2026	Instagram
The person in this Reel is not a real live recording. It is a...	August 9, 2026	Instagram
A "skin callus" is completely made up and not a legitimate...	August 9, 2026	Instagram

[그림4]


"The airspace violation is real, but the post adds unsupported political claims. NORAD reported that more than 10 general-aviation aircraft entered temporary restricted airspace over Bedminster and East Rutherford on July 19; three were intercepted by F-16s and all were safely escorted out. There is no indication these aircraft were intentional threats to Trump, or that the incident was connected to his political enemies." — 30

[그림5]

실제 Community Notes 적용 사례에서는 트럼프의 베드민스터 자택 인근 제한 구역에 여러 항공기가 진입하여 미군 전투기가 출동했다는 내용의 게시물이 검토되었다. 이 게시물은 경공 침범 사건을 트럼프에 대한 의도적인 위협 및 정치적 적대 세력과 연결하여 설명하였다[그림3]. 이에 **Community Notes는 제한 구역 침범과 전투기 출동 자체는 사실이지만**, 해당 항공기들이 트럼프를 의도적으로 위협했거나 트럼프의 정치적 적대 세력과 관련되었다는 **주장을 뒷받침할 근거는 없다고** 설명하였다[그림5](현재 Community Notes는 미국에 한하여 적용되고 있기 때문에 실제 사례는 Meta가 공개한 Community Notes 사례 페이지

를 통해 실제 노트의 내용을 확인하였다[8]. Community Notes 전문은 개발자 도구에서 확인하였다.) 위 사례를 확인하면 Community Notes는 사용자가 직접 게시물에 대한 **추가적인 정보와 근거를 제공한다는 장점**이 있다. 그러나 현재는 미국에 제한하여 적용되고 있다는 단점이 있고 노트의 작성이 **사용자의 참여에 의존**하기 때문에 게시물이 게시된 직후에는 설명이 제공되지 않을 수 있고 모든 게시물이 검토된다는 보장도 없다는 **단점**이 있다.

위 두 사례 외에도 TikTok의 **미확인 콘텐츠 경고 기능**이 있다. TikTok은 허위 및 오해 유발 콘텐츠의 확산을 감소시키기 위해 **외부 팩트체크 기관과 협력**하여 영상의 정확성을 검토하며 해당 콘텐츠가 거짓으로 판별되면 해당 콘텐츠를 플랫폼에서 삭제하고 있다.



[그림6]

사실 확인이 불확실한 콘텐츠의 경우에는 사용자에게 **“Caution: Video flagged for unverified content.”**라는 **안내 배너**가 표시되며 이는 사용자 추천 대상에서 제외될 수 있다[그림6]. 또는 영상 제작자에게도 자신의 콘텐츠가 미확인 콘텐츠로 표시되었다는 사실이 통보된다. 또한 해당 콘텐츠를 공유하려고 하면 TikTok은 영상이 검증되지 않았다는 사실을 안내하고 공유 여부를 다시 생각하도록 유도한다[9]. 이 기능은 사실 여부가 확인되지 않은 콘텐츠의 확산을 줄이고 사용자의 신중한 공유를 유도한다는 장점이 있다. 그러나 영상에 포함된 여러 정보들 중 어느 부분이 확인되지 않았는지, **어떤 자료들을 바탕으로 그러한 결과가 나왔는지에 대한 근거는 사용자에게 제공되지 않는**다는 단점이 있다. 또한 외부 팩트체크 기관의 검토가 선행되어야하므로 모든 콘텐츠를 게시 직후에 분석하기 어렵다는 단점이 있다.

1. 작품 설계

- 목표 : 작품 설계 시 어떤 점에 중점을 두고, 무엇을 목표로 설계했는지 기술
- 작동 원리 : 구현하고자하는 작품의 작동 방법, 원리에 대해 상세히 기술
- 작품 설계 : 작품 외관, SW 작동 구조 등 작품의 외·내적 설계 기술

2. 작품 제작

- 각 작품의 제작 과정을 상세히 기술

III 작품 테스트

1. 테스트 목적 : 테스트 시행 목적 기술

2. 테스트 방법 : 테스트를 진행하는 주체, 대상, 방법, 사용된 도구, 도구의 활용법 등을 상세히 기술

3. 예상 결과 : 예상했던 결과를 기재

4. 실제 결과 : 계획에 따라 실시된 테스트의 결과를 수집된 데이터와 함께 기술

5. 결과 분석 : 테스트 전 예상치와 실제 결과를 비교 분석

IV 해석 & 결론

1. 제작 현황 : 테스트 결과에 따라 작품에 대한 결론(제품 실용성, 응용 가능성, 기존 제품과의 차별성 등)

2. 추후 개선사항 : 결론에 따라 추가적인 개선점을 기술